



UNIVERSIDAD ANDRÉS BELLO
FACULTAD DE INGENIERÍA
INGENIERÍA CIVIL INFORMÁTICA

Sistema de Gestión Inteligente de Recetas y Presupuestos para Repostería y Cocina

Informe de Avance – Proyecto de Título

Infraestructura, Base de Datos, Backend, Frontend y Prototipo IA

BRUNO IGNACIO PAINAMIL NAVIA
Profesor guía: Pablo Hernán Schwarzenberg Riveros

SANTIAGO - CHILE
Junio, 2026

Índice General	
Abstract.....	4
Resumen.....	4
1. Introducción	5
2. Revisión bibliográfica y análisis comparativo de aplicaciones.....	6
2.1 Estado del arte	6
Aplicaciones de recetas para usuarios domésticos	6
Sistemas ERP para la industria de alimentos	6
Inteligencia Artificial aplicada a gastronomía.....	6
2.2 Tabla comparativa.....	6
2.3 Análisis crítico – El diferenciador	7
3. Metodología y objetivos.....	8
3.1 Enfoque de desarrollo: SCRUM.....	8
3.2 Metodología del módulo de IA	8
3.3 Construcción de la matriz heurística	8
3.4 Objetivo general y específicos	9
4. Base de Datos	10
4.1 Tecnología utilizada	10
4.2 Diagrama de Entidades	10
4.3 Descripción de las tablas.....	12
users — Usuarios.....	12
ingredients — Catalogo de ingredientes.....	12
recipes y recipe_ingredients — Recetas	12
substitutes — Sustitutos de ingredientes (Módulo IA)	13
quotes y quote_items — Cotizaciones	13
unit_conversions — Conversiones de unidades	13
5. Backend - API REST	14
5.1 Lenguaje y Frameworks utilizados	14
5.2 Estructura del BackEnd	14
5.3 Endpoints de la API	14
Autenticación.....	14
Ingredientes	14
Recetas.....	15
Cotizaciones	15
5.4 Formula de cálculo de cotizaciones (temporal)	15
5.5 Testeo de la API	16
6. FrontEnd - Aplicación Web.....	18
6.1 Tecnología utilizada	18
6.2 Conexión con Backend	18

6.3 Módulos	18
Inicio de sesión y registro	18
Módulo de Recetas	20
Módulo de Ingredientes	22
Módulo de Cotizaciones	23
6.4 Diseño visual.....	25
7. Infraestructura y Despliegue	26
7.1 Docker y Docker Compose	26
7.2 Variables de entorno	26
8. Módulo de Inteligencia Artificial – Implementación incremental	27
8.1 Contexto y objetivo.....	27
8.2 Síntesis de Experimentación con Algoritmos de Aprendizaje Automático	27
8.3 Representación vectorial y Datasets utilizados.....	27
8.4 Decisiones técnicas y método de aprendizaje.....	28
8.5 Métricas del prototipo.....	29
8.6 Estado actual y limitaciones	32
9. Valorización del proyecto y proyección de retorno	33
9.1 Valorización del esfuerzo de desarrollo	33
9.2 Modelo de negocio y precio de venta.....	33
9.3 Componentes de valor adicional	34
10. Plan de Trabajo	35
10.1 Cumplimiento del plan de trabajo.....	35
10.2 Estado del sistema en producción	35
11. Análisis crítico de resultados.....	36
12. Conclusiones	37
12.1 Trabajo futuro.....	37
12.2 Enlace al repositorio GitHub	37
13. Referencias.....	38

Abstract

This report presents the final progress of the Intelligent Recipe and Budget Management System for Bakery and Cooking. Building on the infrastructure, database, backend and frontend delivered in the previous increment, this version incorporates the fully trained K-Nearest Neighbors (KNN) artificial intelligence module for ingredient substitution recommendations. The module supports three substitution scenarios: unavailable ingredients, vegan diet restriction, and gluten-free (celiac) diet restriction. Additionally, this report includes a comparative analysis of existing applications in the market, a critical discussion of the AI module design decisions, the cost valuation of the development effort, and a preliminary return-on-investment projection for the system.

Resumen

El presente informe documenta el avance final del Sistema de Gestión Inteligente de Recetas y Presupuestos para Repostería y Cocina. Sobre la infraestructura, base de datos, BackEnd y FrontEnd entregados en el incremento anterior, esta versión incorpora el módulo de Inteligencia Artificial completamente entrenado, basado en el algoritmo K-Nearest Neighbors (KNN), para la recomendación de sustitutos de ingredientes. El módulo cubre tres escenarios de sustitución: ingrediente no disponible, restricción vegana y restricción sin gluten (celiaco). Además, este informe incluye un análisis comparativo de aplicaciones existentes en el mercado, una discusión crítica de las decisiones de diseño del módulo IA, una valorización del esfuerzo de desarrollo y una proyección preliminar de retorno sobre la inversión.

1. Introducción

La repostería y la cocina artesanal son actividades que exigen precisión técnica, especialmente en el contexto de pequeños negocios que deben gestionar simultáneamente el control de recetas, el cálculo de costos y la generación de presupuestos para clientes. Existe una brecha tecnológica clara entre las aplicaciones de recetas orientadas al hogar y los sistemas ERP corporativos diseñados para grandes cadenas. Ninguno de estos extremos sirve de manera adecuada al segmento de pymes y emprendedores gastronómicos.

Este informe documenta el cierre del segundo incremento de desarrollo de la herramienta, que completa el módulo de Machine Learning e incorpora una comparativa de aplicaciones similares con análisis del diferenciador, y la valorización económica del proyecto con proyección de recuperación de la inversión.

El resultado es un sistema completamente operativo con inteligencia artificial real integrada: al consultar sustitutos de un ingrediente, la aplicación web muestra resultados calculados por el modelo KNN entrenado con 83 ingredientes de repostería y 415 pares de sustitutos almacenados en la base de datos de producción.

2. Revisión bibliográfica y análisis comparativo de aplicaciones

2.1 Estado del arte

Con el propósito de fundamentar la propuesta de valor del sistema desarrollado, se realizó una revisión de las soluciones tecnológicas existentes orientadas a la gestión de recetas y presupuestos en el rubro gastronómico. Esta revisión se organiza en tres categorías: aplicaciones de recetas para usuarios domésticos, sistemas ERP para la industria de alimentos, y sistemas con componentes de inteligencia artificial aplicada a la gastronomía.

Aplicaciones de recetas para usuarios domésticos

Las plataformas más populares en este segmento son Recipe Keeper, RecipeChef, ReciMe y My Recipe Box. Todas permiten almacenar, categorizar y buscar recetas de forma personal. Algunas incluyen listas de compras y planificación de menús semanales. Sin embargo, su foco es el usuario doméstico: no cuentan con módulos de cotización, generación de presupuestos, escalado pensado para producción comercial ni ninguna forma de recomendación inteligente de sustitutos de ingredientes.

Sistemas ERP para la industria de alimentos

En el otro extremo del espectro se encuentran soluciones como JustFood ERP (de Aptean) y los módulos de restaurante de Oracle. Estos sistemas ofrecen control de inventarios, gestión de compras, contabilidad y trazabilidad de ingredientes. Algunos integran módulos de recetas a nivel de producción masiva. Sin embargo, su enfoque es macro y administrativo: están diseñados para grandes cadenas con múltiples sucursales y suponen un costo de implementación y capacitación que resulta completamente inviable para una pyme o un emprendedor independiente.

Inteligencia Artificial aplicada a gastronomía

En el ámbito de IA culinaria, destacan proyectos como RecipeGPT, que usa modelos de lenguaje para generar recetas a partir de un título o lista de ingredientes. La plataforma Toolify explora la generación automática de recetas de pasteles mediante IA generativa. Sin embargo, ninguna de estas herramientas aborda la sustitución inteligente de ingredientes con base en propiedades culinarias cuantificadas, ni las integra dentro de un sistema de gestión comercial que incluya cotizaciones y escalado de porciones.

2.2 Tabla comparativa

La siguiente tabla compara las aplicaciones revisadas con el sistema desarrollado en esta tesis en las dimensiones funcionales más relevantes para el segmento objetivo:

Función	Recipe Keeper	JustFood ERP	RecipeGPT	Este sistema
Gestión de recetas	Si	Si	No	Si
Escalado automático de porciones	Básico	Si	No	Si
Cálculo de costos por receta	No	Si	No	Si
Generación de cotizaciones	No	Parcial	No	Si
Seguimiento de pedidos por estado	No	Si	No	Si
Sustitutos de ingredientes con IA	No	No	No	Si
Filtros veganos / sin gluten	No	No	No	Si
Orientado a pymes y emprendedores	Si	No	Si	Si
Costo accesible para emprendedores	Si	No	Si	Si (a proyectar)

2.3 Análisis crítico – El diferenciador

El análisis comparativo pone en evidencia una brecha tecnológica clara que justifica el desarrollo de este sistema de recetas y recomendaciones. Las aplicaciones de recetas domésticas (Recipe Keeper, ReciMe) cubren bien la organización personal de recetas, pero carecen totalmente de capacidades comerciales: sin costeo, sin cotizaciones y sin ninguna forma de IA para sustitutos. Los sistemas ERP (JustFood) cubren el lado comercial, pero son inaccesibles para pymes por su costo y complejidad. Los sistemas de IA culinaria (RecipeGPT) generan contenido, pero no gestionan operaciones de negocio.

El diferenciador de este sistema es único y se justifica con la combinación de tres capacidades: (1) gestión operativa completa orientada a pymes gastronómicas, (2) cálculo financiero automático de presupuestos con margen configurable, y (3) recomendación inteligente de sustitutos de ingredientes mediante Machine Learning con filtros de restricciones alimentarias. Ninguna solución existente revisada combina las tres.

Adicionalmente, el sistema cubre un caso de uso específico y sin solución directa en el mercado: la repostera independiente que recibe un pedido para 80 personas necesita saber cuántos gramos de cada ingrediente comprar, cuanto le va a costar y como puede reemplazar el huevo si su cliente es vegano, todo en una sola herramienta accesible desde el navegador.

3. Metodología y objetivos

3.1 Enfoque de desarrollo: SCRUM

El desarrollo sigue la metodología Scrum adaptada al contexto de trabajo individual, con “sprints” o incrementos mensuales. Dado que este proyecto está siendo llevado por solo un desarrollador, los roles de Product Owner, Scrum Master y Desarrollador recaen en la misma persona, mientras que el profesor guía actúa como Stakeholder principal que valida los avances y retroalimenta la dirección del proyecto.

Cada sprint produce un incremento funcional verificable: el primer incremento entregó la infraestructura, base de datos, BackEnd y FrontEnd; el segundo incremento, documentado en este informe, entrego el módulo de IA completamente integrado.

3.2 Metodología del módulo de IA

Para el módulo de recomendación de sustitutos se siguió un proceso de experimentación iterativa:

- Primera iteración: se experimentó con un clasificador Random Forest entrenado sobre el dataset público de Food.com (73.000+ recetas de repostería). El modelo alcanzo un 79% de accuracy prediciendo la presencia de ingredientes estructurales, pero se determinó que la coocurrencia estadística no equivale a sustituibilidad. El modelo recomendaba ingredientes que suelen acompañar al huevo (harina, azúcar), no ingredientes que lo pueden reemplazar, lo que, en definitiva, no cumplía con el propósito del proyecto.
- Segunda iteración: se diseñó un enfoque basado en similitud de propiedades culinarias usando el algoritmo KNN. Se construyo una Matriz Heurística Propia de 83 ingredientes parametrizados en 5 dimensiones culinarias, se normalizo con “StandardScaler”, se calculó la similitud coseno y se pre-calcularon los 415 pares de sustitutos que se almacenan en PostgreSQL para consulta en tiempo real.

3.3 Construcción de la matriz heurística

Ante la inexistencia de una base de datos publica que cuantifique las propiedades mecánicas de la repostería en forma numérica estandarizada, se construyó una Matriz Heurística propia. Los valores en escala 0-10 para variables como el poder aglutinante, la humedad y la capacidad leudante fueron modelados y parametrizados a partir de la revisión cualitativa de literatura especializada, principalmente BakeWise de Shirley O. Corriher y The Flavor Bible de Karen Page, y ajustados empíricamente para entrenar el espacio vectorial del algoritmo. Esta decisión metodológica

convierte una limitación del estado del arte en una contribución original de la tesis: la creación de un vocabulario cuantitativo para las propiedades culinarias de los ingredientes de repostería.

3.4 Objetivo general y específicos

Objetivo General: Desarrollar un sistema web funcional que permita a emprendedores del rubro de la repostería gestionar recetas, escalar ingredientes y generar cotizaciones, incorporando un módulo de recomendación inteligente de sustitutos basado en Machine Learning.

Objetivos Específicos:

- Implementar una base de datos relacional con modelo de datos que soporte recetas, ingredientes con propiedades culinarias y cotizaciones, desplegada en entorno Docker.
- Desarrollar una API REST con autenticación JWT y Endpoints para escalado automático de porciones y cálculo de presupuestos con margen configurable.
- Entrenar un modelo KNN sobre propiedades culinarias de 83 ingredientes y pre-calcular sustitutos para tres escenarios: reemplazo general, restricción vegana y restricción celíaca.

4. Base de Datos

4.1 Tecnología utilizada

La base de datos fue implementada con PostgreSQL, un sistema gestor de bases de datos relacional de Código abierto, ampliamente utilizado en la industria por su robustez, soporte de transacciones y compatibilidad con lenguajes de programación modernos. PostgreSQL fue elegido por sobre otras alternativas como MySQL por su soporte nativo del tipo de dato UUID como clave primaria, lo que garantiza la unión de registros incluso en entornos distribuidos.

El esquema de la base de datos fue escrito en SQL estándar y se carga automáticamente al inicializar el contenedor de base de datos por primera vez. Además, incluye datos de prueba precargados para que la aplicación funcione desde el primer arranque.

4.2 Diagrama de Entidades

El siguiente diagrama muestra las 8 tablas del sistema y sus relaciones. Las flechas indican que una tabla referencia a otra mediante una clave foránea (FK).




Figura 1: Diagrama Entidad-relación del sistema. Las 8 tablas cubren los módulos de usuarios, recetas, ingredientes, cotizaciones y el módulo IA.

4.3 Descripción de las tablas

A continuación, se describe el propósito de cada tabla del sistema:

users — Usuarios

Almacena los datos de los usuarios registrados en el sistema (nombre, email y contraseña). La contraseña nunca se guarda en texto plano: se aplica un algoritmo de hash llamado “bcrypt” que la convierte en una cadena irreversible. Cada usuario solo puede ver y editar sus propias recetas y cotizaciones.

ingredients — Catalogo de ingredientes

Es una de las tablas más importantes del sistema. Además de los datos básicos de cada ingrediente (nombre, unidad de medida y precio por unidad), almacena cinco propiedades culinarias en escala del 0 al 10 que son utilizadas por el modelo de inteligencia artificial para calcular similitudes entre ingredientes:

- `binding_power`: que tan bien une o da estructura a la mezcla (por ejemplo, el huevo tiene valor 9).
- `moisture`: que tanta humedad aporta al producto final (la leche tiene valor 9).
- `fat_content`: su contenido de grasa (la mantequilla tiene valor 10).
- `sweetness`: su nivel de dulzor (el azúcar tiene valor 10).
- `leavening`: su capacidad de hacer crecer la masa (el polvo de hornear tiene valor 10).

Respecto a los precios, en esta versión de prueba los valores están definidos manualmente en pesos chilenos (CLP) en base a precios de referencia de mercado. Sin embargo, una mejora futura importante es permitir que el propio usuario edite los precios de sus ingredientes directamente en la aplicación, ya que los costos reales varían según el proveedor y la región. también se contempla a futuro la integración con fuentes de precios en tiempo real para que los presupuestos sean aún más precisos.

recipes y recipe_ingredients — Recetas

La tabla `recipes` guarda los datos generales de cada receta: nombre, categoría (torta, galleta, pan, etc.), número de porciones base, tiempos de preparación e instrucciones. La tabla `recipe_ingredients` actúa como puente entre una receta y sus ingredientes, guardando la cantidad y la unidad específica de cada ingrediente en esa receta. Esta estructura es la que permite el escalado automático de porciones: si una receta base es para 12 personas y se necesita para 36, el sistema simplemente multiplica cada cantidad por 3.

substitutes — Sustitutos de ingredientes (Módulo IA)

Esta tabla guarda los pares de sustitutos calculados por el modelo de inteligencia artificial. Por ejemplo: "el gel de linaza puede reemplazar al huevo con un 85% de similitud". Incluye el puntaje de similitud, la razón textual explicando porque son similares, y si el sustituto es apto para dietas veganas o sin gluten. Esta tabla es llenada desde el notebook de entrenamiento en Google Colab y luego importada a la base de datos de producción.

quotes y quote_items — Cotizaciones

La tabla quotes guarda los datos de cada cotización generada: la receta base, el cliente, las porciones solicitadas y los porcentajes de cálculo. La tabla quote_items guarda el detalle de cada ingrediente escalado con su costo unitario y subtotal. Una cotización puede tener cuatro estados: borrador, enviada, aceptada o rechazada, lo que permite hacer seguimiento de los pedidos.

unit_conversions — Conversiones de unidades

Tabla auxiliar que permite al sistema convertir automáticamente entre distintas unidades de medida comunes en repostería: tazas, gramos, mililitros, cucharadas y cucharaditas. Viene precargada con 13 conversiones estándar.

5. Backend - API REST

5.1 Lenguaje y Frameworks utilizados

El BackEnd fue desarrollado en Python, lenguaje elegido principalmente por dos razones: es el lenguaje dominante en el ecosistema de inteligencia artificial y Machine Learning (scikit-learn, numpy, pandas), lo que permite que el mismo lenguaje utilizado para entrenar el modelo KNN sea también el que construye la API. Esto evita la necesidad de puentes o conversiones entre tecnologías.

Como Framework web se utilizó FastAPI, que permite construir una API REST de forma rápida y con validación automática de los datos. Una ventaja clave de FastAPI es que genera automáticamente una documentación interactiva disponible en el navegador (Swagger UI), lo que facilita el testeo de cada Endpoints sin necesidad de herramientas adicionales.

5.2 Estructura del BackEnd

El Código del BackEnd está organizado en cuatro capas con responsabilidades separadas:

- Modelos: definen la estructura de las tablas de la base de datos en Python, usando el ORM SQLAlchemy.
- Esquemas: definen el formato esperado de los datos que llegan y salen de la API, usando Pydantic para validación automática.
- Servicios: contienen la lógica de negocio, como el cálculo de escalado de ingredientes o la generación del precio final de una cotización.
- Routers: definen los Endpoints HTTP y delegan el trabajo a los servicios.

5.3 Endpoints de la API

A continuación, se describen los principales grupos de Endpoints disponibles en el sistema:

Autenticación

Método	Ruta	Función
POST	/auth/register	Registrar un nuevo usuario con email y contraseña
POST	/auth/login	Iniciar sesión y obtener token de acceso (JWT)
GET	/auth/me	Ver los datos del usuario que está conectado

Ingredientes

Método	Ruta	Función
GET	/ingredients	Listar todos los ingredientes, con filtros de búsqueda

Método	Ruta	Función
POST	/ingredients	Agregar un nuevo ingrediente al catalogo
PUT	/ingredients/{id}	Editar los datos de un ingrediente existente
GET	/ingredients/{id}/substitutes	Ver los sustitutos recomendados por el modelo IA

Recetas

Metodo	Ruta	Función
GET	/recipes	Listar las recetas del usuario con buscador
POST	/recipes	Crear una nueva receta con sus ingredientes
PUT	/recipes/{id}	Editar una receta existente
DELETE	/recipes/{id}	Eliminar una receta
GET	/recipes/{id}/scale?servings=N	Escalar los ingredientes a N porciones con costo estimado

Cotizaciones

Metodo	Ruta	Funcion
POST	/quotes	Generar una cotización automática desde una receta
GET	/quotes	Ver todas las cotizaciones del usuario
GET	/quotes/{id}	Ver el detalle completo de una cotización
PATCH	/quotes/{id}/status	Cambiar el estado de la cotización
DELETE	/quotes/{id}	Eliminar una cotización

5.4 Formula de cálculo de cotizaciones (temporal)

Al generar una cotización, el sistema sigue tres pasos automáticos:

Primero, escala todos los ingredientes de la receta al número de porciones solicitadas por el cliente, multiplicando cada cantidad por el factor de escala correspondiente.

Segundo, calcula el costo total de ingredientes sumando el costo de cada uno (cantidad escalada multiplicada por el precio por unidad).

Tercero, aplica la siguiente fórmula para calcular el precio final sugerido al cliente:

$$\text{Precio Final} = \text{Costo Ingredientes} \times (1 + \text{Gastos Indirectos}\%) \times (1 + \text{Margen}\%)$$

Los gastos indirectos cubren costos como electricidad, gas y tiempo de preparación, que el usuario define como porcentaje.

El margen es la ganancia deseada sobre el costo total. Por ejemplo, con un costo de ingredientes de \$5.000, un 20% de gastos indirectos y un 30% de margen, el precio sugerido seria $\$5.000 \times 1.20 \times 1.30 = \7.800 .

5.5 Testeo de la API

FastAPI genera automáticamente una interfaz Swagger UI disponible en <http://localhost:8000/docs> (testeo local en la máquina) donde es posible probar cada Endpoint de forma interactiva directamente desde el navegador, incluyendo autenticación con usuario y contraseña.



Figura 2: Documentación interactiva Swagger UI con todos los Endpoints disponibles del sistema.




Figura 3: Panel de autorización OAuth2 en Swagger UI. El usuario ingresa sus credenciales y el sistema emite un token JWT para las solicitudes protegidas.




Figura 4: Respuesta exitosa del Endpoints de registro de usuario, mostrando el objeto creado con su identificador único.

6. FrontEnd - Aplicación Web

6.1 Tecnología utilizada

La interfaz de usuario fue desarrollada con React 18, una librería de JavaScript ampliamente utilizada para construir aplicaciones web interactivas. Como herramienta de construcción y servidor de desarrollo se utilizó Vite, que ofrece tiempos de arranque muy rápidos y actualización en tiempo real al editar el código.

La aplicación sigue el patrón SPA (Single Page Application): toda la interfaz se carga una sola vez en el navegador y las navegaciones entre secciones no requieren recargar la página, lo que entrega una experiencia fluida similar a una aplicación de escritorio.

6.2 Conexión con Backend

La comunicación entre el FrontEnd y el Backend se realiza mediante solicitudes HTTP a la API REST, usando la librería “Axios”. Cuando el usuario inicia sesión, el sistema recibe un token JWT del Backend y lo guarda en el navegador. A partir de ese momento, cada solicitud que hace el FrontEnd incluye automáticamente ese token en el encabezado, de modo que el Backend puede verificar la identidad del usuario sin que este tenga que ingresar sus credenciales nuevamente.

Para el manejo del estado del servidor (listas de recetas, ingredientes, cotizaciones) se utiliza React Query, que gestiona automáticamente la carga de datos, el caché y la actualización de la interfaz cuando se detectan cambios.

6.3 Módulos

Inicio de sesión y registro

La pantalla de autenticación permite tanto ingresar con una cuenta existente como crear una cuenta nueva. El formulario alterna entre ambos modos sin cambiar de página. Una vez autenticado, el usuario es redirigido automáticamente a su lista de recetas.




Figura 5: Interfaz de la aplicación web mostrando el inicio de sesión con cuenta ya registrada.




Figura 6: Interfaz de la aplicación web mostrando el formulario de registro.

Módulo de Recetas

Permite crear recetas con nombre, categoría, descripción, tiempos de preparación y lista de ingredientes. Cada ingrediente se selecciona del catálogo y se especifica su cantidad y unidad para esa receta en concreto. Las recetas existentes pueden editarse o eliminarse. El botón "Escalar" abre un panel donde el usuario ingresa el número de porciones deseadas y el sistema muestra en tiempo real las cantidades ajustadas de cada ingrediente junto al costo estimado de materias primas.

The image shows a web application interface for a bakery. On the left is a sidebar with the logo 'Repostería Bruno Painamil' and navigation links: 'Recetas' (highlighted), 'Ingredientes', and 'Cotizaciones'. At the bottom of the sidebar is a 'Cerrar sesión' button. The main content area is titled 'Mis Recetas' and contains a search bar and a card for a recipe titled 'Torta de algo'. A modal window titled 'Nueva receta' is open in the center. It contains the following fields: 'Nombre *' with the example 'Ej: Torta de chocolate', 'Categoría' with a dropdown menu showing 'Sin categoría', a 'Descripción' text area, 'Porciones base' with a value of '8', 'Prep. (min)' with a value of '0', and 'Cocción (min)' with a value of '0'. Below these are 'Ingredientes' and 'Instrucciones' sections, each with a text area. The 'Instrucciones' section has the text 'Paso 1: Precalentar el horno...'. At the bottom of the modal are 'Cancelar' and 'Guardar receta' buttons. A '+ Nueva receta' button is visible in the top right corner of the main content area.

Figura 7: Interfaz de la aplicación web mostrando el formulario de añadir una nueva receta.




Figura 8: Interfaz de la aplicación web mostrando el formulario de editar una receta ya existente.




Figura 9: Interfaz de la aplicación web mostrando el apartado de escalado para una porción indicando medidas y el precio.

Módulo de Ingredientes

Muestra el catálogo completo de ingredientes disponibles en el sistema. Cada ingrediente presenta barras visuales que representan sus cinco propiedades culinarias (aglutinante, humedad, grasa, dulzor, leudante). Al hacer clic en un ingrediente, el panel lateral muestra los sustitutos recomendados por el modelo de IA, con su porcentaje de similitud, la razón del porque pueden reemplazarse y si son aptos para dietas veganas o sin gluten.




Figura 10: Interfaz de la aplicación web mostrando la página de ingredientes, en la imagen se aprecia el ingrediente mantequilla seleccionado. A la derecha se indica el detalle del ingrediente y su ingrediente equivalente químicamente con opción vegana y sin gluten.




Figura 11: Interfaz de la aplicación web mostrando la página de ingredientes, en la imagen se aprecia el ingrediente leche seleccionado. A la derecha se indica el detalle del ingrediente y su ingrediente equivalente químicamente con opción vegana, esta figura ya cuenta con ingredientes cargados y el modelo KNN implementado

Módulo de Cotizaciones

El usuario selecciona una receta, especifica las porciones que pide el cliente, define el porcentaje de gastos indirectos y el margen de ganancia deseado. Con esos datos, el sistema genera automáticamente la cotización con el desglose de ingredientes escalados y el precio final sugerido.

Cada cotización puede cambiar de estado (borrador, enviada, aceptada o rechazada) para hacer seguimiento del pedido. Un panel de resumen muestra el total de ingresos acumulados de cotizaciones aceptadas.




Figura 12: Interfaz de la aplicación web mostrando el formulario de creación de cotización con selección de la receta y cantidades



Figura 13: Interfaz de la aplicación web mostrando una cotización realizada con una receta ya existente con su estado como borrador.

6.4 Diseño visual

La aplicación utiliza un diseño propio de tema oscuro con colores cálidos que evocan el ambiente de una repostería artesanal. Se utilizan dos tipografías: Playfair Display para los títulos, que aporta elegancia editorial, y DM Sans para el texto funcional, que garantiza legibilidad. El sistema de colores incluye un color terracota como color de acción principal y un dorado para indicadores secundarios.

7. Infraestructura y Despliegue

7.1 Docker y Docker Compose

Todo el sistema se ejecuta mediante Docker, una herramienta que permite empaquetar aplicaciones en contenedores aislados que funcionan de la misma forma en cualquier computador, independientemente del sistema operativo. El proyecto utiliza Docker Compose para orquestar dos contenedores que trabajan en conjunto:

- Contenedor de base de datos (reposteria-db): ejecuta PostgreSQL con un volumen persistente, lo que significa que los datos no se pierden cuando el sistema se apaga.
- Contenedor del Backend (reposteria-api): ejecuta Python con FastAPI. Este contenedor espera a que la base de datos esté lista antes de arrancar, evitando errores de conexión.

Para levantar el sistema completo desde cero solo se necesita ejecutar un único comando en la terminal: **“docker-compose up –build”**

El FrontEnd de React se ejecuta por separado con “npm run dev” durante el desarrollo.

7.2 Variables de entorno

Los datos sensibles como la clave secreta para los tokens JWT y la contraseña de la base de datos se configuran mediante variables de entorno definidas en un archivo “.env”, que no se sube al repositorio de Código. Esto es una práctica estándar de seguridad para evitar exponer credenciales.

8. Módulo de Inteligencia Artificial – Implementación incremental

8.1 Contexto y objetivo

Uno de los aspectos diferenciadores de este sistema es la capacidad de recomendar sustitutos de ingredientes de forma inteligente. Esto es especialmente útil para reposteros que necesitan adaptar una receta porque un ingrediente no está disponible, es muy caro, o el cliente tiene restricciones alimentarias (vegano, sin gluten).

Para desarrollar y probar este módulo se utilizó Python en Google Colab, un entorno de programación gratuito basado en navegador que permite ejecutar Código Python con facilidad. Google Colab fue elegido porque facilita el trabajo con librerías de machine Learning sin necesidad de configurar un entorno local.

8.2 Síntesis de Experimentación con Algoritmos de Aprendizaje Automático

El desarrollo del módulo de Inteligencia Artificial pasó por dos iteraciones metodológicas para determinar el enfoque algorítmico más preciso aplicado a la gastronomía:

- Iteración 1: Random Forest sobre co-ocurrencia estadística. Se entrenó un modelo de clasificación supervisada utilizando un *dataset* público proveniente de Food.com (vía Kaggle), del cual se aislaron 73.000 recetas de repostería. Tras aplicar *One-Hot Encoding* a los 100 ingredientes más frecuentes, el modelo alcanzó una precisión (*Accuracy*) del 79.08% prediciendo si una receta necesitaba un ingrediente estructural (como el huevo). Sin embargo, se concluyó que la co-ocurrencia estadística no equivale a sustituibilidad: el modelo aprendió que la harina y el azúcar suelen acompañar al huevo, pero no que un ingrediente externo (como el gel de linaza) puede reemplazarlo funcionalmente. Esto llevó a descartar el enfoque probabilístico por frecuencia.
- Iteración 2: K-Nearest Neighbors (KNN) sobre propiedades culinarias. Se estructuró un conjunto de datos enfocado en las propiedades funcionales de los ingredientes. En lugar de predecir la necesidad de un ingrediente, el algoritmo KNN busca los "vecinos más cercanos" en un espacio multidimensional, encontrando aquellos que comparten el mismo perfil de comportamiento químico y mecánico dentro de una mezcla.

8.3 Representación vectorial y Datasets utilizados

Para el entrenamiento final, se abandonó la base de datos de recetas en favor de una matriz heurística propia, cuyos valores fueron modelados y parametrizados a partir de la revisión cualitativa de bases de datos gubernamentales (USDA FoodData Central) y literatura culinaria especializada (*BakeWise* de Shirley O. Corriher y *The Flavor Bible* de Karen Page).

El dataset definitivo cuenta con 83 ingredientes categorizados en grupos clave (aglutinantes, harinas y almidones, grasas, azúcares, lácteos y leudantes). Cada ingrediente queda definido matemáticamente como un vector de 5 propiedades culinarias en una escala del 0 al 10:

```
v(ingrediente) = [binding_power, moisture, fat_content,
                  sweetness, leavening]
```

Propiedad	Descripción	Ejemplo: huevo
binding_power	Capacidad de unir y estructurar la masa	9 / 10
moisture	Aporte de humedad al producto final	7 / 10
fat_content	Contenido graso que aporta textura	5 / 10
sweetness	Nivel de dulzor intrínseco	0 / 10
leavening	Capacidad de hacer crecer la masa	1 / 10

Además, el modelo incluye metadatos binarios (0 o 1) para aplicar filtros duros según restricciones dietéticas (is_vegan para ingredientes veganos, is_gluten_free para ingredientes libres de gluten) y una variable de referencia para análisis de costos (precio_clp).

8.4 Decisiones técnicas y método de aprendizaje

Se eligió el algoritmo K-Nearest Neighbors (KNN) porque el problema de sustituir ingredientes es fundamentalmente un problema de similitud: dado un ingrediente, encontrar cuales otros tienen propiedades culinarias parecidas. Este es exactamente el tipo de problema que KNN resuelve de forma natural.

Un algoritmo de clasificación como Random Forest fue descartado para esta tarea, ya que respondería preguntas del tipo “¿qué ingredientes se suelen llevar con huevos?”, pero no “que ingrediente se parece más al huevo en sus propiedades”. El prototipo inicial contemplaba un intento con Random Forest que demostró no ser el enfoque correcto, ya que el modelo tendía a predecir siempre la clase mayoritaria por el desbalance del dataset.

Las decisiones de diseño técnico que garantizan la precisión del sistema son:

Similitud coseno: se usó `metric="cosine"` en lugar de distancia euclidiana. La similitud coseno mide el ángulo entre dos vectores de ingredientes, capturando el perfil relativo de comportamiento culinario independientemente de la magnitud absoluta de los valores. La fórmula es: $\cos(\theta) = (A \cdot B) / (\|A\| * \|B\|)$. Esto implica que un ingrediente con propiedades [8,6,3,0,0] será reconocido como similar a [9,7,5,0,1] aunque sus valores absolutos difieran.

Normalización StandardScaler: antes de calcular distancias, cada propiedad se normaliza a media=0 y desviación estandar=1. Sin esto, una propiedad con valores típicamente altos dominaría el cálculo.

Arquitectura de precálculo: el modelo no corre en tiempo real al hacer una consulta web. “Se precálculan” todos los pares de sustitutos en Google Colab, se exportan a CSV y se importan a la tabla substitutes de PostgreSQL. Cuando un usuario consulta sustitutos, la app hace un SELECT simple. Esto garantiza respuestas en milisegundos sin dependencia de Python en producción.

Conversión a score de similitud: la distancia coseno $[0,2]$ se convierte a score $[0,1]$ con la formula $\text{similitud} = 1 - \text{distancia}/2$, haciendo el resultado intuitivo para el usuario final.

8.5 Métricas del prototipo

Al tratarse de un sistema de recomendación sin etiquetas de verdad absoluta (no existe una única respuesta correcta para "que reemplaza al huevo"), la evaluación del modelo se realizó de forma cualitativa y mediante métricas de coherencia:

Análisis de distribución y justificación de normalización:

El análisis exploratorio de las 5 dimensiones culinarias (Poder Aglutinante, Humedad, Contenido Graso, Dulzor y Capacidad Leudante) demostró distribuciones fuertemente sesgadas. Tal como se observa en el histograma generado




Figura 14: Gráfico generado del Google colab del modelo KNN para visualizar distribución de propiedades culinarias de los ingredientes

La mayoría de los ingredientes presentan valores de cero en propiedades específicas (por ejemplo, la inmensa mayoría de los insumos no poseen capacidad leudante, concentrándose en el rango 0). Esta distribución asimétrica validó empíricamente la necesidad arquitectónica de aplicar un StandardScaler previo al entrenamiento, garantizando que ninguna variable dominara el cálculo de similitud solo por tener una escala mayor.

Visualización del espacio vectorial (PCA 2D)

Para comprender cómo el algoritmo agrupa los ingredientes en su "mente", se aplicó un Análisis de Componentes Principales (PCA) que redujo el espacio multidimensional a un plano bidimensional.




Figura 15: Gráfico generado del Google colab del modelo KNN de la reducción dimensional mediante Análisis de Componentes Principales (PCA)

- **Varianza:** El modelo PCA logró capturar y explicar un **57% de la varianza total** de los datos (PC1: 32%, PC2: 24%), lo cual es un porcentaje de retención altamente efectivo al comprimir 5 dimensiones en 2.
- **Agrupación semántica:** La gráfica demuestra que el modelo matemático logró replicar la taxonomía culinaria de forma lógica. Los "Leudantes" (bicarbonato, polvos de hornear) se aíslan en el cuadrante superior izquierdo, mientras que los "Aglutinantes" forman un clúster definido en la zona derecha, posicionando de forma contigua al huevo, el gel de chía, el gel de linaza y el psyllium husk (Cáscara de Psyllium).

Matriz de similitud coseno

Para cuantificar la exactitud del algoritmo, se generó un mapa de calor (*Heatmap*) evaluando la similitud del coseno entre ingredientes clave.




Figura 16: Gráfico de matriz de similitud generado del Google colab del modelo KNN

Adicionalmente, se ejecutaron pruebas de estrés sobre el algoritmo arrojando los siguientes porcentajes de precisión:

- **Sustitutos estructurales (Escenario Vegano):** Al solicitar un reemplazo para el huevo, el sistema recomendó las alternativas exactas utilizadas en la repostería basada en plantas: Gel de linaza (98.3%), Gel de chía (97.0%) y Tofu sedoso (95.6%).
- **Sustitución de Harinas (Escenario Celíaco):** Al filtrar alternativas libres de gluten para la "Harina de trigo", el algoritmo identificó con éxito perfiles mecánicos similares en la Harina de avena (99.2%), Harina de arroz (97.8%) y Tapioca (97.6%).
- **Diferenciación lógica:** La matriz de similitud comprobó que el sistema no confunde ingredientes estructurales incompatibles. Por ejemplo, el cruce entre la harina de trigo y la harina de almendra arrojó una similitud negativa (-0.23), demostrando que la IA comprende que la primera aporta estructura seca y la segunda aporta principalmente humedad y grasa.

Filtros y resultados

Durante la generación del dataset final para el despliegue de la base de datos, se aplicó un umbral estricto para descartar cualquier par que presentara una similitud inferior al 10% (0.10), previniendo sugerencias sin sentido culinario. Como resultado de este proceso, el algoritmo generó exitosamente 415 pares de sustitutos viables a partir de un universo de 83 ingredientes evaluados, cubriendo todos los cruces necesarios para los tres escenarios de uso (reemplazo general, dieta vegana y dieta sin gluten).

8.6 Estado actual y limitaciones

El análisis crítico del módulo permite identificar las siguientes limitaciones que orientan el trabajo futuro:

- El dataset de 83 ingredientes, aunque suficiente para validar la viabilidad del enfoque, es reducido para una aplicación en producción. Expandir a 200+ ingredientes mejoraría significativamente la cobertura de recomendaciones.
- Los precios actuales son valores de referencia estimados, no precios reales del mercado chileno. La precisión de las cotizaciones mejoraría sustancialmente al permitir que el usuario ingrese sus propios precios de proveedor.
- El modelo asume que las propiedades culinarias son fijas, sin considerar variaciones por marca, madurez del ingrediente o método de preparación.

9. Valorización del proyecto y proyección de retorno

9.1 Valorización del esfuerzo de desarrollo

Para estimar el costo de desarrollo del sistema, se contabilizaron las horas invertidas por fase según el plan de trabajo original y el registro real de avance. Se utiliza una tarifa de referencia de mercado para un desarrollador junior-mid con conocimientos de Python, React y Machine Learning en Chile (aproximadamente \$25.000 CLP por hora, equivalente a USD 27/hora al cambio actual):

Fase	Actividad	Horas estimadas	Horas reales
Fase 1	Infraestructura, Git, Docker, entorno	25	28
Fase 2	Diseño de base de datos y esquema SQL	20	22
Fase 3	Backend FastAPI (endpoints, auth, lógica)	100	115
Fase 4	Frontend React (3 módulos, diseño)	80	95
Fase 5	Módulo IA (experimentación, KNN, integración)	130	140
Fase 6	Documentación e informes	60	65
TOTAL		415 horas	465 horas

Costo total de desarrollo estimado: 465 horas x \$25.000 CLP = \$11.625.000 CLP (aproximadamente USD 12.500 al tipo de cambio actual).

Este costo refleja el esfuerzo de un desarrollador individual. Un equipo de tres personas (BackEnd, FrontEnd, data scientist) podría reducir el tiempo en un 40% pero multiplicaría el costo por factor de 3, resultando en un costo similar. La ventaja del desarrollo individual es el ahorro en coordinación y comunicación.

9.2 Modelo de negocio y precio de venta

Para proyectar el precio de comercialización del sistema, se evalúan dos modelos de negocio alternativos:

- **Modelo SaaS (Software as a Service):** el sistema se ofrece como servicio en la nube con suscripción mensual. Este es el modelo más adecuado para el segmento objetivo (pymes y emprendedores) porque elimina la barrera de instalación y permite ingresos recurrentes.
- **Modelo de licencia única:** venta del sistema con instalación local. Apropiado para negocios que prefieren no depender de internet o que tienen preocupaciones de privacidad de datos.

Concepto	Modelo SaaS	Modelo Licencia
Precio al cliente	\$15.000 - \$25.000 CLP/mes	\$350.000 - \$500.000 CLP (pago único)
Cientes necesarios para recuperar inversión	46 - 77 clientes	23 - 33 licencias
Tiempo estimado de recuperación	6 - 18 meses	Inmediato si se venden 23+
Ventaja principal	Ingreso recurrente y actualizable	Pago único sin dependencia
Costo de mantenimiento	Servidor cloud ~\$30 USD/mes	Solo soporte bajo demanda

9.3 Componentes de valor adicional

Mas allá del precio directo del software, el sistema genera valor económico cuantificable para sus usuarios:

- Reducción de errores en cotizaciones: una cotización manual errónea en un pedido de 100 porciones puede significar una pérdida de entre \$5.000 y \$30.000 CLP por receta. Con el cálculo automático, este error se elimina.
- Ahorro de tiempo en presupuestos: una cotización que manualmente toma 20-30 minutos (calcular cantidades, buscar precios, sumar costos) se genera automáticamente en menos de 1 minuto.
- Valor diferenciador de la IA: la recomendación de sustitutos permite a la repostera responder inmediatamente a un cliente vegano o celiaco sin perder la venta, algo que actualmente requiere búsqueda manual en internet o conocimiento experto.

10. Plan de Trabajo

10.1 Cumplimiento del plan de trabajo

A continuación, se deja un plan de los próximos avances esperados a partir de los siguientes meses:

#	Actividad	Plazo	Estado
1	Ejecutar notebook KNN con 83 ingredientes y exportar CSV	Julio 2026	Completado
2	Importar 415 pares de sustitutos a PostgreSQL	Julio 2026	Completado
3	Integrar módulo IA en el FrontEnd con filtros	Julio 2026	Completado
4	Comparativa de aplicaciones y análisis crítico	Julio 2026	Completado
5	Valorización del proyecto y proyección ROI	Julio 2026	Completado
6	Permitir edición de precios por usuario	Agosto 2026	Pendiente
7	Validación con repostero real	Agosto 2026	Pendiente
8	Exportación de cotizaciones en PDF	Septiembre 2026	Pendiente
9	Fase QA con usuario real	Octubre 2026	Pendiente
10	Informe final de proyecto de título	Noviembre 2026	Pendiente

10.2 Estado del sistema en producción

A la fecha de este informe, el sistema está completamente operativo en entorno local con Docker.

Los resultados verificables son:

- Base de datos: 8 tablas, 83 ingredientes con propiedades culinarias, 415 pares de sustitutos reales del modelo KNN, 13 conversiones de unidades.
- BackEnd: 18 Endpoints REST documentados en Swagger UI, autenticación JWT, lógica de escalado y cotización automática.
- FrontEnd: 3 módulos funcionales (recetas, ingredientes, cotizaciones) con diseño propio oscuro.
- Módulo IA: modelo KNN entrenado con similitud coseno, 3 escenarios de sustitución (general, vegano, sin gluten), scores reales en producción.

11. Análisis crítico de resultados

Los resultados del módulo KNN son coherentes con el conocimiento culinario experto, lo que valida la pertinencia del enfoque de similitud de propiedades culinarias como proxy de sustituibilidad. Sin embargo, el análisis crítico del prototipo revela aspectos que merecen reflexión:

Sobre la métrica de similitud: la similitud coseno captura bien el perfil relativo de las propiedades, pero no distingue entre ingredientes que comparten un perfil de comportamiento en diferentes contextos. Por ejemplo, el “aquafaba” (liquido de garbanzos) y la gelatina sin sabor aparecen como similares al huevo en poder aglutinante y humedad, pero su comportamiento difiere en preparaciones que requieren horneado versus preparaciones en frío. Una mejora futura sería agregar una propiedad de contexto de uso.

Sobre los datos: la Matriz Heurística propia construida es una contribución metodológica de este proyecto, pero tiene la limitación de ser subjetiva y dependiente del criterio del autor o datos de páginas no estandarizados. Una validación externa con chefs o pasteleros profesionales que puedan confirmar o ajustar los valores de las propiedades fortalecería significativamente la robustez del modelo.

Sobre la arquitectura de precálculo: la decisión de pre-calcular todos los pares de sustitutos en Colab e importarlos a PostgreSQL es la mejor opción para el contexto actual del proyecto, pero implica que el modelo no se actualiza automáticamente al agregar nuevos ingredientes. Para cada expansión del catálogo será necesario volver a ejecutar el notebook y reimportar los resultados. Una arquitectura futura podría incluir un Endpoint que reentrene el modelo automáticamente al agregar ingredientes.

Sobre la primera iteración con Random Forest: el intento inicial con Random Forest, aunque no resultó el enfoque correcto para la tarea de sustitución, no fue tiempo perdido. Permitió comprender en profundidad la estructura de los datos de recetas de repostería y confirmar que la coocurrencia de ingredientes tiene un patrón estadístico identificable, lo que abre la puerta a futuras aplicaciones como la sugerencia automática de recetas complementarias basadas en ingredientes disponibles.

12. Conclusiones

Este informe documenta la entrega de un sistema de gestión de recetas y presupuestos / cotizaciones para repostería completamente operativo, con un módulo de inteligencia artificial integrado que genera recomendaciones de sustitutos de ingredientes basadas en similitud de propiedades culinarias calculada mediante el algoritmo KNN.

El análisis comparativo con las soluciones existentes confirma que ninguna aplicación del mercado combina las tres capacidades que diferencian a este sistema: gestión operativa comercial para pymes, cálculo automático de presupuestos con margen configurable, y recomendación inteligente de sustitutos con filtros de restricciones alimentarias. Esta combinación responde a una necesidad real y no atendida del mercado de reposteras y pasteleras independientes en Chile.

La valorización del proyecto estima un costo de desarrollo de \$11.625.000 CLP, recuperable en 6 a 18 meses con un modelo SaaS a \$15.000-\$25.000/mes con 46 a 77 clientes, en un mercado objetivo de más de 15.000 microempresarias del rubro en el país.

Las principales limitaciones identificadas son: el tamaño reducido del dataset de ingredientes (83), la ausencia de precios reales por proveedor, y la falta de validación externa del modelo con expertos culinarios. Estas limitaciones orientan el plan de trabajo para los próximos tres meses.

12.1 Trabajo futuro

- Expandir el catálogo a 200+ ingredientes para mejorar la cobertura del modelo KNN.
- Implementar edición de precios por usuario para cotizaciones más precisas.
- Realizar validación del modelo con reposteros y pasteleros profesionales.
- Agregar exportación de cotizaciones en PDF para envío formal a clientes.
- Explorar aprendizaje por retroalimentación: si el usuario rechaza una sugerencia, el modelo ajusta sus pesos.
- Diseñar y ejecutar una fase de pruebas con usuarios reales (QA).
- Preparar el informe final de proyecto de título para la defensa en noviembre 2026.

12.2 Enlace al repositorio GitHub

A continuación, se deja el enlace al repositorio de GitHub:

<https://github.com/BrunixZero/tesis-reposteria-brunopainamil.git>

13. Referencias

- Ingrid Cubas (2023). Los retos que enfrenta la industria de la panadería y pastelería en 2023. THE FOOD TECH.
<https://thefoodtech.com/soluciones-y-tecnologia-alimentaria/los-retos-queenfrenta-la-industria-de-la-panaderia-y-pasteleria-en-2023>
- Julia Martins (2025). Scrum: conceptos clave y cómo se aplica en la gestión de proyectos. Asana <https://asana.com/es/resources/what-is-scrum>
- PostgreSQL. (2024). PostgreSQL 15 Documentation. <https://www.postgresql.org/docs/15/>
- React. (2024). React 18 Documentation. <https://react.dev>
- Scikit-learn. (2024). sklearn.neighbors.NearestNeighbors.
<https://scikit-learn.org/stable/modules/neighbors.html>
- USDA. (2024). FoodData Central. <https://fdc.nal.usda.gov>
- FastAPI. (2024). FastAPI Documentation. <https://fastapi.tiangolo.com>
- Vite. (2024). Vite Documentation. <https://vitejs.dev>
- Aptean. (s.f.). JustFood ERP. <https://www.justfooderp.com>
- Keo Magic. (s.f.). RecipeChef. <https://recipechef.app>
- ReciMe. (s.f.). ReciMe. <https://www.recime.app>
- Tudorspan Software. (s.f.). Recipe Keeper. <https://recipekeeperonline.com>
- Creati.ai (2024). RecipeGPT: Simplificando Resúmenes de Recetas con IA.
Creati.ai <https://creati.ai/es/ai-tools/recipegpt/>